

A correção de composição celular na idade epigenética pode injetar o confundimento que deveria remover

Um índice de risco de transporte, e um conserto de uma linha

Luan Ivepe

Pesquisador independente

luanivepe@gmail.com

Rascunho de preprint — 23/09/2026

Versão em português. A versão de referência, para submissão, é a inglesa.

Resumo A aceleração de idade epigenética em sangue é rotineiramente corrigida pela composição de células imunes, e essa correção é quase sempre estimada e aplicada dentro da mesma coorte. Mostramos que, quando os coeficientes dessa correção são estimados numa coorte e aplicados em outra — a situação sempre que uma correção publicada é reutilizada — o procedimento pode **adicionar** sinal de composição em vez de removê-lo. Ajustando em quarenta amostras e transportando, o termo de composição residual sobe 12,2 pontos da variância de aceleração de idade e a correção fica pior do que não corrigir em 89% dos sorteios; já coeficientes de composição sem informação alguma ficam em +0,5%, com intervalo interquartil atravessando o zero. O dano vem de coeficientes reais mal estimados, não de ruído. A falha é invisível dentro da coorte de ajuste, onde a correção zera o termo de composição por construção. Nem o tamanho amostral nem o condicionamento da matriz de composição da coorte de ajuste explicam o fenômeno — a coorte que falha pior é a mais bem condicionada do conjunto. O que explica é o termo padrão de excesso de risco de mínimos quadrados sob *covariate shift*, $(\sigma^2/n) \cdot \text{tr}(\Sigma_{\text{ajuste}}^{-1} \Sigma_{\text{teste}})$, que chamamos de índice de transporte. Ele ordena 63 configurações direcionadas em quatro coortes de ajuste com ρ de Spearman de 0,907, é assimétrico onde distâncias simétricas não são, e prevê a pior falha observada com meio ponto de erro. Penalizar os coeficientes de composição por ridge limita a amplificação diretamente e mantém os doze pares direcionados em zero ou abaixo, inclusive um transporte que custa +15,9 pontos sem penalidade. A validação cruzada comum na coorte de ajuste **não** dimensiona a penalidade corretamente justamente na coorte que falha. Reportamos o índice como diagnóstico computável de antemão e a penalidade como padrão.

1 Introdução

Sangue é uma mistura, e a mistura muda com a idade. Linfócitos caem, células mieloides sobem, e compartimentos naive dão lugar aos de memória. Como cada subtipo de leucócito carrega o próprio metiloma, um relógio epigenético aplicado a sangue total lê em parte a idade das células e em parte o censo do tubo¹.

O tamanho dessa contaminação já está bem caracterizado. Em resolução de doze tipos, a composição imune explica de 13% a 34% da variância de aceleração de idade, dependendo do relógio², e células T CD8 naive leem 15 a 20 anos mais novas que CD8 de memória efetora do mesmo doador³. Existem duas respostas. Uma projeta o confundimento para fora já na seleção de CpGs³. A outra — muito mais comum, e o objeto deste artigo — subtrai o efeito depois: regreda a idade do relógio sobre a idade cronológica e as proporções celulares estimadas, e guarda o resíduo. Isso é a aceleração de idade epigenética intrínseca, e é computada dentro de qualquer conjunto de dados que esteja à mão.

É esse último detalhe que importa. **Uma correção estimada e avaliada na mesma coorte não pode ser validada ali.** O resíduo de um ajuste de mínimos quadrados é ortogonal aos seus preditores por construção, então o termo de composição é levado a exatamente zero independentemente de quanto os coeficientes valham. Qualquer avaliação de se a correção funciona precisa portanto ser feita fora da coorte — e o próprio artigo de referência da área, que compara oito métodos de correção de tipo celular, não testa transferência entre conjuntos de dados para nenhum deles¹.

¹Genome Biology 17:84 (2016), “An evaluation of methods correcting for cell-type heterogeneity in DNA methylation studies”; PMC4855979. Lista de autores a conferir antes da submissão.

Transferência não é hipótese. Sempre que uma correção publicada é reutilizada, que uma coorte clínica de algumas dezenas é corrigida com coeficientes de um estudo maior, ou que dois grupos comparam estimativas corrigidas, coeficientes atravessam uma fronteira de coorte. Perguntamos o que acontece quando atravessam.

2 Métodos

2.1 Coortes, painéis de referência e relógios

Quatro séries públicas de sangue total em 450k com idade cronológica: GSE40279 ($n = 656$, idades 19–101), GSE61151 ($n = 184$), GSE50660 ($n = 464$) e GSE42861 ($n = 689$). As proporções celulares foram estimadas por mínimos quadrados não negativos com restrição, contra dois painéis de referência construídos aqui: um painel de seis tipos a partir de Reinius et al. (GSE35069) e um de doze tipos a partir da referência FlowSorted.BloodExtended.EPIC (GSE167998)⁴. Nosso painel de doze tipos usa uma seleção de sondas por estatística t mais simples que a biblioteca IDOL publicada, e recupera as proporções conhecidas das doze misturas reconstruídas com r de 0,79 e erro absoluto médio de 0,027; todo número de composição aqui deve ser lido como um piso do que a biblioteca publicada alcança. O canal de monócito do painel corre alto, e nenhum coeficiente de monócito por tipo é interpretado.

Três relógios com coeficientes publicados e abertos sustentam a análise: Horvath 2013, Levine 2018 (PhenoAge) e Horvath 2018. Hannum 2013 foi treinado no GSE40279 e é excluído sempre que essa coorte aparece.

2.2 A correção, e como ela é pontuada

A correção é a padrão. Na coorte de ajuste, ajustamos $y = \beta_0 + \beta_1 a + C\beta_c$, em que y é a idade do relógio, a a idade cronológica e C as proporções estimadas (uma coluna descartada, já que somam um); guardamos β_c e aplicamos $y - (C_{\text{teste}} - \bar{C}_{\text{ajuste}})\beta_c$ na coorte de teste. A idade cronológica permanece no modelo de ajuste — composição deriva com a idade, e omiti-la arrancaria envelhecimento real junto com o hemograma — mas só os coeficientes de composição viajam, então aplicar a correção não exige idade.

O desfecho é o termo de composição que sobra no resíduo de idade da coorte de teste: o incremento em R^2 ao acrescentar composição a um modelo da idade do relógio sobre a idade cronológica, menos um nulo de permutação, como fração da variância de aceleração de idade não corrigida. **Ajuste e medição usam painéis diferentes** — ajustado com doze tipos, medido com seis — porque pontuar uma correção com a própria representação dela é pontuá-la contra o próprio relato do que removeu. Reportamos $\Delta = \text{depois} - \text{antes}$; positivo significa que a correção deixou o relógio pior do que não corrigir.

2.3 O índice de transporte

Escreva o erro de estimação como $e = \hat{\beta}_c - \beta_c$. A correção transportada deixa $-C_{\text{teste}}e$, cuja variância na coorte de teste é $e'\Sigma_{\text{teste}}e$. Para mínimos quadrados, $\text{Cov}(e) = \sigma^2/n \cdot \Sigma_{\text{ajuste}}^{-1}$, logo

$$\mathbb{E}[\text{dano}] \propto \left(\frac{\sigma^2}{n} \right) \cdot \text{tr}(\Sigma_{\text{ajuste}}^{-1} \Sigma_{\text{teste}}).$$

Chamamos $\text{tr}(\Sigma_{\text{ajuste}}^{-1} \Sigma_{\text{teste}})/n$ de **índice de transporte**. Ambas as matrizes de segundo momento são tomadas depois de retirar intercepto e idade cronológica, que é o espaço onde os coeficientes vivem.

Não reivindicamos novidade para essa quantidade. Ela é o termo padrão de excesso de risco de mínimos quadrados sob *covariate shift* — a situação em que a distribuição das covariáveis muda entre treino e aplicação — e o modo de falha que ela descreve tem nome nessa literatura: *spectral inflation*, direções que carregam pouca variação no treino e mais na avaliação⁵. Há também teoria sobre escolher a regularização ridge sob *covariate shift*⁶. O que é novo aqui é a observação de que uma correção epidemiológica de uso corrente está exposta a isso, e a medição de quando o problema morde.

Para ridge com penalidade λ , o termo correspondente é $\text{tr}(M\Sigma_{\text{ajuste}}M\Sigma_{\text{teste}})/n$, com $M = (\Sigma_{\text{ajuste}} + \lambda I)^{-1}$. As penalidades são citadas como α , um multiplicador livre de escala do autovalor médio do produto cruzado padronizado, de modo que o mesmo α signifique a mesma coisa em todo n e em toda coorte. Os coeficientes são ajustados por Frisch–Waugh–Lovell sobre colunas padronizadas e devolvidos à escala original; em $\alpha = 0$ isso reproduz exatamente o ajuste sem penalidade.

2.4 Subamostragem

Onde uma coorte de ajuste é subamostrada, os sorteios são **estratificados por decil de idade**. Um sorteio não estratificado de quarenta, numa coorte que vai de 19 a 101 anos, estreita e desloca a faixa etária, o que confundiria tamanho amostral com faixa de treino. Ao longo da grade, a idade mediana de um sorteio fica a menos de 0,5 ano da coorte cheia, e a amplitude entre os percentis 10 e 90 dentro de 2% dela.

3 Resultados

3.1 Uma correção transportada pode ser pior do que não corrigir




Figura 1. A correção é nociva abaixo de aproximadamente 160 amostras de ajuste. Composição que sobra no resíduo de idade depois do transporte, como fração da variância de aceleração de idade; acima de zero, a correção deixou o relógio pior do que não mexer nele. Correções ajustadas em subamostras estratificadas por idade do GSE40279 e levadas a três coortes externas, 30 sorteios por ponto, três relógios. As linhas cinza são as três coortes de teste separadamente. A régua laranja é o mesmo transporte com coeficientes de composição ajustados sobre composição embaralhada, que não carregam informação por construção.

Ajustando a correção em subamostras do GSE40279 e transportando-a para três coortes externas (Figura 1), a mediana de Δ cruza zero entre n de 160 e n de 184. Abaixo disso a correção padrão é pior do que não fazer nada, e no fundo da faixa não é por pouco: com quarenta amostras, Δ chega a +12,2% e a correção é nociva em 89% dos sorteios. Expressa contra o sinal de composição que estava presente, a correção em n igual a 40 não remove 0% dele — ela **adiciona 2,7 vezes** o que havia. Com as 656 completas, remove 61% fora da coorte. A linha de referência importa para a interpretação. Coeficientes de composição ajustados sobre composição **embaralhada** não carregam informação, e transportá-los produz uma mediana de Δ de +0,5%, com intervalo interquartil de -0,8% a +2,1% sobre 180 sorteios — uma distribuição que atravessa o zero. Coeficientes sem sentido são praticamente inofensivos. São os coeficientes reais, estimados em amostras de menos, que causam o dano, e causam cerca de vinte vezes mais dele do que o ruído causa.

A mediana não é a história toda. Tomando o espalhamento entre sorteios **dentro** de cada célula relógio-por-coorte, o quartil superior da célula mediana só cai abaixo de zero por volta de $n \approx 320$: o sorteio típico começa a ajudar perto de 160 a 184, mas um sorteio azarado continua prejudicando bem depois disso.

3.2 Nem tamanho amostral nem condicionamento explicam

Tamanho amostral é causa forte e não suficiente. Ajustar em 184 amostras do GSE40279 e transportar dá Δ de $-0,9\%$ — levemente benéfico — enquanto ajustar nas 184 do próprio GSE61151 e transportar para o GSE40279 dá $+5,0\%$, com os três relógios prejudicados. Alguma coisa na coorte de ajuste, além do tamanho dela, está fazendo o trabalho.

O candidato natural é o condicionamento: proporções celulares colineares dão coeficientes instáveis, e fatores de inflação de variância acima de 100 são documentados como capazes de inverter o sinal da maioria dos coeficientes nesse contexto⁷. No nosso painel de doze tipos, o maior fator de inflação de variância vai de 215 a 302, pior que os 113,7 relatados com seis tipos. Mas o condicionamento mal se move com n — o número de condição do bloco de composição residualizado é 65,9 em n igual a 40 e 54,5 em n igual a 656 — e, dentro de cada célula n -por-relógio-por-coorte, não carrega informação alguma sobre o dano (ρ de Spearman mediano de $-0,025$, positivo em 48% das células, um cara ou coroa).

Decisivamente: **o GSE61151, a coorte cuja correção transportada falha pior, é a mais bem condicionada do conjunto** (número de condição 40,8, maior VIF 117,8, contra 54,4 a 65,9 e 212 a 302 para toda subamostra do GSE40279, inclusive a coorte cheia). O condicionamento da coorte de ajuste sozinho não pode ser o mecanismo.

3.3 O índice de transporte ordena o dano




Figura 2. O índice de transporte ordena 63 configurações direcionadas. Cada ponto é uma configuração (coorte de ajuste, coorte de teste, tamanho de ajuste); a forma do marcador dá a coorte de ajuste. Spearman de 0,907. Nenhuma configuração abaixo de um índice de 0,05 foi nociva; 81% acima dele foram.

O índice é uma propriedade conjunta das duas coortes, que é exatamente o motivo de medir Σ_{ajuste} sozinha não ter dado nada: uma Σ_{ajuste} bem condicionada pode ainda assim ter $\Sigma_{\text{ajuste}}^{-1}$ amplificando justamente as direções em que Σ_{teste} guarda variância.

Em 63 configurações direcionadas montadas a partir de quatro coortes de ajuste, o índice ordena o dano mediano com ρ de 0,907 ($p = 2 \times 10^{-24}$; Figura 2), e faz isso dentro de cada coorte de ajuste separadamente — 0,858, 0,951, 0,907 e 0,897 — de modo que a ordenação não é propriedade da escada de subamostras de uma coorte. O dano cruzou zero perto de um índice de 0,05: **nenhuma** das 21 configurações abaixo desse valor foi

nociva, e 81% das acima foram. Entre 0,05 e 0,16 ocorrem os dois desfechos, então o limiar é um piso de um lado só, não um ponto de travessia.

Um resultado negativo pertence a esta seção. O índice **não** prevê o dano de um sorteio individual: com n e coorte de teste fixos, o ρ mediano é 0,021 em 56% das células, pior que a grandeza que ele deveria superar. A teoria prevê isso. Com n e a coorte de teste fixos, Σ_{ajuste} é quase idêntica entre sorteios, então o índice mal varia, enquanto o e'/Σ_{teste} realizado é do tipo qui-quadrado com onze graus de liberdade. Um preditor quase constante não consegue acompanhar um desfecho dominado por ruído de realização. O índice prevê dano esperado entre configurações, não o sorteio à sua frente.




Figura 3. O índice é assimétrico, e o dano também. Cada par reversível ajustado nas duas direções em $n = \min(n_A, n_B)$, de modo que só a covariância de ajuste muda. O laranja marca a direção que o índice chama de pior; ela está à direita do marcador vazado em cinco de seis. No sexto (GSE40279 / GSE42861) os dois índices são 0,0275 e 0,0271 — o índice previu indiferença e foi pontuado como se tivesse previsto uma direção.

Distâncias simétricas entre estruturas de covariância de composição não dão conta desse trabalho, e a assimetria é a razão. Ajustado em n casado, de modo que só a covariância de ajuste difere, o índice nomeia a direção pior em cinco de seis pares reversíveis (Figura 3; binomial p de 0,109, que não é significância e não é apresentado como tal — com seis pares, nenhum limiar simultaneamente passa de 0,05 e tolera um erro). O erro é um par cujos dois índices são 0,0275 e 0,0271: o índice previu indiferença e foi pontuado como se tivesse previsto direção.

Para a configuração que derrotou nossas tentativas anteriores, o índice de GSE61151 $\rightarrow$ GSE40279 é 0,174 contra 0,038 do seu próprio reverso, uma razão de 4,6. Um índice perto de 0,18 corresponde a cerca de +4,6% de dano na Figura 2; o valor medido é +5,0%.

Uma simulação fecha o mecanismo. Sorteando duas coortes sintéticas com o **mesmo** vetor de coeficientes verdadeiros, o mesmo ruído e o mesmo n , de modo que a única coisa que pode dar errado é estimação atravessando um desencontro de covariância, trocar qual covariância faz o ajuste move o resíduo de +21,2% para +84,6% em n igual a 40. Os resíduos observados regredem sobre os previstos com inclinação 0,92 pela origem e r de 0,815.

3.4 Penalizar os coeficientes remove a falha




Figura 4. Ridge mantém os doze transportes direcionados em zero ou abaixo. Cada linha é um par direcionado de cortes em $n = \min(n_A, n_B)$; a seta vai do ajuste sem penalidade até $\alpha = 3$.

Ridge substitui $\Sigma_{\text{ajuste}}^{-1}$ por $(\Sigma_{\text{ajuste}} + \lambda I)^{-1}$ e limita a amplificação diretamente. Uma penalidade só conta como conserto se remove o dano e preserva o benefício: encolher uma correção até zero remove o dano e não é método. Exigindo, antes da rodada, que a penalidade não seja pior que não corrigir em n igual a 40 e retenha ao menos 70% do benefício sem penalidade em n igual a 656, exatamente um valor da nossa grade qualifica, $\alpha = 3$. A curva dele é plana — entre $-1,4\%$ e $-2,0\%$ ao longo de uma faixa de dezesseis vezes em tamanho de ajuste — e é esse o ponto: a correção deixa de depender de quão grande era a coorte de ajuste. Já $\alpha = 10$ é a esquina degenerada que o critério foi escrito para pegar: norma dos coeficientes 13, dano preso perto de $-0,9\%$ em toda parte, inofensivo e inútil.

O mesmo α , obtido independentemente a partir da coorte real que falhou, leva aquele transporte de $+5,0\%$ para $-0,5\%$. Nos doze pares direcionados em n casado, mantém a mediana em zero ou abaixo (Figura 4), inclusive GSE61151 → GSE42861, o pior transporte que encontramos, que vai de $+15,9\%$ para $-2,5\%$. Não é de graça: onde a correção sem penalidade já transporta bem, a penalidade custa parte do benefício — GSE40279 → GSE42861 abre mão da maior parte dele, de $-2,8\%$ para $-0,7\%$. Penalizar é seguro, e seguro tem prêmio nos casos que não precisavam.

A validação cruzada não basta para dimensioná-la. Leave-one-out na coorte de ajuste escolhe sensatamente em subamostras do GSE40279 e, na coorte que de fato quebra o transporte, escolhe $\alpha = 0.3$ e deixa $+2,9\%$ do dano de pé. A validação cruzada otimiza predição dentro da coorte de ajuste, e esse objetivo não sabe que os coeficientes estão prestes a ser embarcados para outro lugar.

3.5 O diagnóstico sobrevive a duas equipes e dois painéis de referência

Tudo acima usa uma mesma deconvolução nas duas pontas de cada transporte, o que não é a situação de que o resultado trata. Estimando a composição da coorte de ajuste a partir de uma referência e a da coorte de teste a partir de outra — os mesmos seis rótulos, doadores, sondas e geração de array diferentes — os dois painéis concordam bem (r mediano por tipo de $0,936$), e o índice ainda ordena as configurações com ρ de $0,776$, contra $0,793$ para painéis casados. Duas referências discordando sobre um tipo celular são um desencontro de

covariância, então o índice enxerga sem precisar ser avisado. Ridge com $\alpha = 3$ mantém os doze pares em zero ou abaixo também no braço desencontrado.

4 Discussão

Três coisas decorrem disso para a prática.

Primeiro, uma correção estimada dentro da coorte não pode ser validada nessa coorte. Isso é aritmética, não achado empírico, e se aplica a todo artigo que reporta uma aceleração de idade intrínseca sem uma checagem fora da coorte. A perfeição aparente da correção em casa é garantida e não carrega informação.

Segundo, coortes de ajuste pequenas não são meramente ruidosas. Um vetor de coeficientes sem informação nenhuma praticamente não faz nada quando transportado. Coeficientes reais estimados em quarenta amostras adicionam 2,7 vezes o sinal de composição que estava presente. A falha não é uma versão diluída do sucesso.

Terceiro, o risco é computável de antemão. O índice de transporte precisa apenas das proporções estimadas das duas coortes e do tamanho de ajuste — nenhum desfecho, nenhuma segunda coorte de validação, nenhum rótulo retido. Abaixo de 0,05 não observamos dano em 63 configurações. Não leríamos isso como garantia, e sim como um limiar que vale calcular antes de reutilizar uma correção publicada.

Nossa recomendação é mais estreita que “use ridge e valide cruzadamente”. Penalize — e não deixe a validação cruzada na coorte de ajuste decidir sozinha quanto.

5 Limitações

Quatro coortes, todas de sangue total em 450k, todas adultas, e doze pares direcionados. A contagem de assimetria é seis. Os dois painéis de referência são construídos aqui com seleção de sondas mais crua que as bibliotecas publicadas, então a discordância entre eles é um piso do que dois laboratórios reais produziriam. O valor $\alpha = 3$ é este painel com estes relógios; o que esperaríamos que transportasse é “penalize”, não o número. O índice é derivado para mínimos quadrados com um termo de composição linear corretamente especificado, e a simulação que confirma sua constante assume exatamente isso. E o índice prevê dano esperado entre configurações, não o sorteio individual — um resultado negativo que reportamos em vez de enterrar.

Nada aqui diz respeito a se relógios epigenéticos medem algo real. Esta é uma afirmação sobre uma correção aplicada a eles.

6 Disponibilidade de dados e código

As cinco séries são públicas: GSE40279, GSE61151, GSE50660, GSE42861 (sangue total), GSE35069 e GSE167998 (painéis de referência). Nenhum dado de terceiros é redistribuído. O código de análise, o registro etapa a etapa completo — incluindo toda conclusão posteriormente derrubada — e os scripts das figuras estão em github.com/KTHimiko/clock-lab.

Antes da submissão — a conferir

- A lista de autores do artigo de benchmark de oito métodos da Genome Biology 2016 (PMC4855979) e a do preprint de *covariate shift* arXiv:2312.17463 não foram confirmadas, e estão marcadas como tal em vez de adivinhadas.
- O repositório está privado no momento; precisa estar público antes de o preprint citá-lo.
- Falta uma declaração de reprodutibilidade e as versões exatas dos pacotes.

Referências

1. Jaffe, A. E. & Irizarry, R. A. Accounting for cellular heterogeneity is critical in epigenome-wide association studies. *Genome Biology* **15**, R31 (2014).
2. Zhang, Z., Salas, L. A., Christensen, B. C. & others. Deciphering the role of immune cell composition in epigenetic age acceleration: insights from cell-type deconvolution applied to human blood epigenetic clocks. *Aging Cell* **23**, e14071 (2024).

3. Tomusiak, A. & others. Development of an epigenetic clock resistant to changes in immune cell composition. *Communications Biology* **7**, 934 (2024).
4. Salas, L. A., Koestler, D. C., Christensen, B. C. & others. Enhanced cell deconvolution of peripheral blood using DNA methylation for high-resolution immune profiling. *Nature Communications* **13**, 761 (2022).
5. [AUTHOR LIST NOT VERIFIED]. Out of the Ordinary: Spectrally Adapting Regression for Covariate Shift. (2023).
6. Patil, P. & [CO-AUTHORS NOT VERIFIED]. Optimal Ridge Regularization for Out-of-Distribution Prediction. (2024).
7. Meredith, J. M., Melton, P. E., Huang, R.-C. & others. In epigenomic studies, including cell-type adjustments in regression models can introduce multicollinearity, resulting in apparent reversal of direction of association. *Frontiers in Genetics* **10**, 816 (2019).