

Correções de composição celular da idade epigenética podem, quando transportadas, adicionar o confundimento que deveriam remover

Ruído de estimação, model shift, e uma penalidade como salvaguarda

Luan Ivepe

Pesquisador independente

luanivepe@gmail.com

Rascunho de preprint, revisado após parecer — 25/09/2026

Versão em português. A versão de referência, para submissão, é a inglesa.

Resumo A aceleração de idade epigenética em sangue é rotineiramente corrigida pela composição de células imunes, regredindo a idade do relógio sobre as proporções celulares estimadas. Dentro da coorte onde é ajustada, a correção faz o que promete. Estudamos o caso em que seus coeficientes são aplicados a outra coorte. Em quatro coortes públicas de sangue total, pontuando só relógios que nunca treinaram nas coortes envolvidas, uma correção ajustada em quarenta amostras e transportada aumentou o sinal de composição em 93% dos sorteios nos relógios que estimam idade, e no eixo naive/memória dos linfócitos o aumento foi três a quatro vezes o que um painel de seis tipos mostra; num relógio de ritmo de envelhecimento, o DunedinPACE, o mesmo transporte em amostra pequena foi neutro. O erro tem duas partes. O ruído de estimação, amplificado pelas diferenças de covariância de composição entre as coortes, cai com $1/n$ e é reproduzido quase exatamente por coeficientes sem informação. O model shift — um efeito de composição que difere entre coortes — não cai com o tamanho de ajuste e responde pelos piores transportes. Como a segunda parte depende dos coeficientes da própria coorte-alvo, nada que pudemos calcular de antemão certificou um transporte como seguro: um previsor em forma fechada rotulou como seguros 30 de 73 transportes nocivos, e o índice de transporte acrescentou só informação modesta além do tamanho amostral (ρ de Spearman dentro de n em torno de 0,36; permutação em blocos com $p = 0,036$). Uma penalidade ridge nos coeficientes de composição reduziu os transportes nocivos (par $\times$ relógio) de metade para 3%, em diferentes painéis de medição e de referência. A validação cruzada na coorte de ajuste escolheu penalidades fracas demais para o mesmo.

1 Introdução

A composição do sangue muda com a idade: linfócitos diminuem, células mieloides aumentam, e células de memória substituem as naive. Cada subtipo de leucócito tem seu perfil de metilação, então um relógio aplicado a sangue total mede em parte a composição da amostra¹. Com doze tipos celulares resolvidos, a composição explica de 13% a 34% da variância de aceleração de idade, conforme o relógio², e células T CD8 naive leem 15 a 20 anos mais novas que CD8 de memória efetora do mesmo doador³.

O remédio usual é regredir a idade do relógio sobre a idade cronológica e as proporções estimadas, e guardar o resíduo. Isso costuma ser feito dentro do próprio conjunto de dados, onde remove exatamente o termo linear de composição. Pelo mesmo motivo não pode ser verificado ali: um resíduo de mínimos quadrados é ortogonal aos preditores qualquer que seja a qualidade dos coeficientes. As avaliações publicadas de ajuste por tipo celular são por simulação e dentro do conjunto de dados⁴.

Examinamos o caso em que os coeficientes saem da coorte que os produziu: reutilização de coeficientes publicados, coortes pequenas que os tomam de coortes maiores, ou uma correção fixa aplicada a amostras novas.

2 Métodos

2.1 Coortes, painéis de referência e relógios

Quatro séries públicas de sangue total em 450k com idade cronológica: GSE40279 ($n = 656$, idades 19–101), GSE61151 ($n = 184$), GSE50660 ($n = 464$, coorte de tabagismo) e GSE42861 ($n = 689$, caso-controle de artrite reumatoide). As proporções foram estimadas por mínimos quadrados não negativos com restrição, contra um painel de seis tipos (GSE35069) e um de doze tipos que separa linfócitos naive e de memória (GSE167998)⁵, ambos construídos aqui; o painel de doze recupera proporções conhecidas de misturas com r de 0,79 e erro absoluto médio de 0,027.

Relógios: Horvath 2013⁶, Levine 2018⁷ e Horvath 2018⁸. Um relógio é excluído de todo par que envolve uma coorte em que ele treinou. Hannum 2013 e Horvath 2013 treinaram no GSE40279 (o Horvath 2013 o lista como conjunto de treino 3; o GSE42861 foi só de teste). Levine 2018 (InCHIANTI) e Horvath 2018 não treinaram em nenhuma das quatro. Os pares com GSE40279 são pontuados só com Levine 2018 e Horvath 2018. Uma quinta coorte, o GSE132203 ($n = 795$, array EPIC, majoritariamente afro-americana), testa a replicação em outra geração de array e outra ancestralidade; nela só se pontuam relógios com cobertura de sondas acima de 95% (Levine 2018, Horvath 2018). Como relógio de outro tipo, acrescentamos o DunedinPACE⁹, que estima o ritmo de envelhecimento e foi treinado numa coorte fora do GEO; nós o reimplementamos a partir dos dados de modelo publicados no pacote e o validamos (médias por coorte de 0,93 a 1,05; fumantes atuais 0,14 mais rápidos que quem nunca fumou, $p = 3 \times 10^{-11}$).

2.2 Correção e pontuação

Na coorte de ajuste, ajustamos $y = \beta_0 + \beta_1 a + C\beta_c$ (idade do relógio y , idade cronológica a , proporções C com uma coluna descartada) e aplicamos $y - (C_{\text{teste}} - \bar{C}_{\text{ajuste}})\beta_c$ na coorte de teste. O desfecho é o termo de composição que sobra no resíduo de idade da coorte de teste — o incremento de R^2 da composição sobre a idade cronológica, menos um nulo de permutação, como fração da variância de aceleração não corrigida. O dano líquido Δ é essa fração depois da correção menos antes; Δ positivo significa que a correção transportada foi pior do que nenhuma. A correção é ajustada com doze tipos e pontuada com seis, para não ser avaliada pela própria representação; análises de sensibilidade pontuam com doze tipos e só com as colunas naive/memória. Toda contagem é por relógio: um par em que um relógio é prejudicado e outro ajudado conta como duas células. Agregar relógios dentro do par escondeu boa parte do dano numa versão anterior desta análise.

2.3 Dois componentes do erro de transporte

Seja b ajustado na coorte A e S_B a covariância de composição da coorte B, ambos depois de retirar intercepto e idade. A composição que sobra em B é $(\beta_B - b)' S_B (\beta_B - b)$. Com $b = \beta_A + e$ e $\text{Cov}(e) = (\sigma^2/n) S_A^{-1}$, seu valor esperado é um termo de especificação $(\beta_A - \beta_B)' S_B (\beta_A - \beta_B)$ mais um termo de estimação $\sigma^2 \cdot \text{tr}(S_A^{-1} S_B)/n$. Chamamos $\text{tr}(S_A^{-1} S_B)/n$ de índice de transporte. O termo de estimação é o excesso de risco padrão de mínimos quadrados sob *covariate shift*¹⁰; o de especificação é *model shift*¹¹. Não reivindicamos nenhum dos dois como novo.

Uma referência sem informação é obtida embaralhando linhas inteiras da matriz de composição da coorte de ajuste antes de ajustar, o que preserva a colinearidade entre tipos. Ela é medida em cada tamanho de ajuste.

2.4 Penalidade, subamostragem e inferência

Os coeficientes ridge são ajustados na composição padronizada e residualizada pela idade, com penalidade α vezes o autovalor médio, para que α seja comparável entre coortes e tamanhos; $\alpha = 0$ reproduz mínimos quadrados. Sob mudança de distribuição a penalidade ótima nem precisa ser positiva¹²; uma penalidade positiva fixa é usada aqui como padrão conservador. As subamostras são estratificadas por decil de idade. Onde as configurações compartilham coortes, a significância é avaliada por permutação em blocos¹³, trocando perfis inteiros de índice entre pares de coortes.

3 Resultados

3.1 Uma correção transportada pode ser pior do que nenhuma




Figura 1. Dano líquido de uma correção transportada, por tamanho de ajuste. Ajustada em subamostras estratificadas por idade do GSE40279 e aplicada a três coortes externas; Levine 2018 e Horvath 2018; 30 sorteios por tamanho. Acima de zero a correção foi pior do que nenhuma. Laranja: o mesmo procedimento com as linhas de composição embaralhadas antes do ajuste.

Ajustada em 40 amostras e transportada, a correção teve Δ mediano de +18,9% (IQR de +8,2% a +34,2%) e foi nociva em 93% dos sorteios (Figura 1). Em três conjuntos independentes de sorteios, a mediana em 40 amostras variou de +11,8% a +18,9%. A mediana ficou perto de zero entre 160 e 240 amostras e em -1,6% nas 656 completas, onde 33% dos valores (relógio $\times$ coorte) ainda eram nocivos. Pontuado com doze tipos em vez de seis, o dano em 40 amostras foi de +48,1%; só nas colunas naïve/memória, +30,6%. Essa medição usa o mesmo painel do ajuste e é enviesada a favor da correção, então a curva de seis tipos subestima o dano.

3.2 Dois componentes




Figura 2. Composição deixada pelos coeficientes reais e pelos embaralhados. O ajuste real mantém um piso de cerca de 4,5 pontos em tamanho cheio; acima desse piso, o excesso acompanha a referência embaralhada.

Coeficientes embaralhados não carregam informação, e mesmo assim deixaram +15,6% de dano líquido em 40 amostras, caindo com o tamanho a uma inclinação log-log de $-0,93$ (Figura 2). A maior parte do dano em amostras pequenas é, portanto, ruído de estimação. O ajuste real, porém, ainda deixou 4,5 pontos de composição em 656 amostras, onde a referência embaralhada deixou 1,0. Descontado esse piso, o resto acompanhou de perto a referência embaralhada (9,6 contra 9,6 pontos em 60 amostras; 3,1 contra 3,1 em 120; 1,2 contra 1,3 em 240).

O piso não é artefato de pontuar com outro painel: aplicada dentro do GSE40279, a mesma correção removeu 95% (Levine) e 85% (Horvath 2018) do sinal de composição de seis tipos. Transportada em tamanho cheio, removeu de 92% a -109% conforme o par — no pior caso, dobrando o sinal.

3.3 Model shift




Figura 3. Termo de especificação contra a composição que sobra em tamanho cheio. 24 configurações (par direcionado × relógio). O termo é corrigido pelo ruído de estimação dos dois ajustes.

O termo de especificação corrigido ordenou a sobra em tamanho cheio com ρ de Spearman de 0,633 ($p = 0,0009$; Figura 3). Ele explica o pior transporte encontrado, do GSE61151 para a coorte de artrite: previsto +26,6% e +51,8% para os dois relógios, observado +30,8% e +30,5%. Os testes de Wald par a par de coeficientes iguais rejeitaram em 4 de 12 comparações após Bonferroni, abaixo da barra pré-definida de 6 (9 de 12 com p nominal abaixo de 0,05). As duas medidas pesam as diferenças de coeficiente de modos distintos: o Wald pela precisão da estimativa, o termo de especificação pela variância na coorte-alvo. Dentro das coortes, os coeficientes do Levine 2018 diferiram entre casos de artrite e controles e entre quem já fumou e quem nunca fumou ($p = 0,013$ cada); para o Horvath 2018 esse teste não rejeitou ($p = 0,61$ e $0,48$). Ajustar por doença e tabagismo deixou as diferenças entre coortes praticamente inalteradas.

O model shift não é efeito de lote. Dentro do GSE42861, onde casos e controles compartilham estudo, array e laboratório, ajustamos a correção numa metade aleatória dos controles e a aplicamos tanto à outra metade quanto aos casos de artrite (30 divisões pareadas). Aplicada aos casos, ela deixou 7,4, 7,4 e 2,6 pontos a mais de composição do que aplicada a controles (Horvath 2013, Levine 2018, Horvath 2018), embora o índice de transporte fosse menor para os casos — então nada do excesso é ruído de estimação, e o componente de model shift estimado foi de 8,7, 8,4 e 6,3 pontos. O Horvath 2018 é afetado mesmo sem o teste de Wald acima detectar diferença de coeficientes. A escolha da população de referência também muda o efeito estimado da doença: no Horvath 2018, o efeito da artrite ajustado por idade foi de $-0,74$ ano com a correção na coorte inteira e de $-1,39$ ano com a correção ajustada só nos controles.

3.4 O que dá para saber antes de transportar




Figura 4. Índice de transporte contra dano líquido, por relógio. Laranja: transportes que o predictor em forma fechada rotulou como seguros e que foram nocivos. A forma do marcador indica a coorte de ajuste.

Como o índice escala com $1/n$, parte da sua correlação com o dano vem só do tamanho amostral. Nos três tamanhos disponíveis para todos os pares, uma permutação em blocos que preserva os tamanhos de cada par deu nulo com mediana de ρ igual a 0,42; o observado foi 0,579 ($p = 0,036$). Dentro de um único tamanho de ajuste, o índice ordenou o dano com ρ de 0,41, 0,36 e 0,33. Ele traz informação real, mas modesta, sobre quais pares são arriscados (Figura 4). Contados por relógio, 12 de 40 transportes com índice abaixo de 0,05 foram nocivos; nenhum limiar do índice delimita uma região segura.

Uma estimativa em forma fechada do dano líquido que supõe coeficientes compartilhados, $2\hat{\sigma}^2 \cdot \text{índice} - b' S_B b$, precisa só da coorte de ajuste e das proporções do alvo. Ela acertou o sinal em 71% das configurações (ρ de 0,633), contra 81% (ρ de 0,884) de um oráculo que conhece os coeficientes do próprio alvo. Ela erra para o lado tranquilizador: 30 dos 73 transportes que rotulou como seguros foram nocivos, concentrados onde o termo de especificação é grande.

3.5 Uma penalidade remove a maior parte do dano




Figura 5. Transporte sem penalidade contra transporte com penalidade ridge, por célula (par × relógio), em tamanho casado $n = \min(n_A, n_B)$.

Sem penalidade, 15 de 30 células (par × relógio) foram nocivas. Com $\alpha = 3$, restou uma, em +0,2% (Figura 5); com $\alpha = 10$, nenhuma. A penalidade tem custo: onde a correção sem penalidade já ajudava, o benefício mediano caiu de -4,0% para -3,3% com $\alpha = 3$ e para -1,5% com $\alpha = 10$. A penalidade fixa também se sustentou quando as duas coortes foram deconvoluídas com painéis de referência diferentes (14 células nocivas sem penalidade, 1 com $\alpha = 3$) e quando pontuada com doze tipos ou no eixo naive/memória (nenhuma célula nociva com $\alpha = 3$).

Escolher a penalidade por validação cruzada leave-one-out na coorte de ajuste não funcionou tão bem: ela escolheu α de 0,3 na célula mediana e deixou 30% das células nocivas, contra 3% com $\alpha = 3$ fixo. A validação cruzada otimiza o ajuste dentro da coorte de ajuste e não enxerga onde os coeficientes serão usados.

3.6 Um relógio de ritmo de envelhecimento

No DunedinPACE, a correção transportada ajustada em 40 amostras do GSE40279 foi neutra (mediana de +0,3%, nociva em 51% dos sorteios), embora os coeficientes embaralhados ainda tenham causado +4,9% de dano: o componente de ruído estava presente, mas os coeficientes reais removeram sinal genuíno suficiente para compensá-lo. Ajustada na quinta coorte, a correção foi neutra de novo (-1,5%, nociva em 42%), então isso parece propriedade do relógio, e não da coorte de ajuste. O resto se repetiu: em tamanhos casados, 6 de 12 pares direcionados foram nocivos sem penalidade e nenhum com $\alpha = 3$, e uma correção ajustada em controles deixou 10,5 pontos a mais de composição em casos de artrite do que em outros controles.

3.7 Replicação em outro array e outra ancestralidade

Ajustada em 40 amostras do GSE132203 (EPIC, majoritariamente afro-americana) e transportada para as quatro coortes de 450k, a correção foi nociva para os relógios de idade em 95% dos sorteios (mediana de +24,3%; Levine 2018 91%, Horvath 2018 99%), com os coeficientes embaralhados em +16,4%. Nos 8 pares direcionados que envolvem essa coorte, 7 de 24 células (par × relógio) foram nocivas sem penalidade e nenhuma com $\alpha = 3$.

4 Discussão

A correção de composição dentro da coorte não pode ser validada dentro dela; isso decorre dos mínimos quadrados, não dos dados. Transportada, o dano em amostras pequenas é sobretudo ruído de estimação — coeficientes embaralhados fazem quase o mesmo estrago —, enquanto o dano em amostras grandes vem de diferenças no efeito da composição entre coortes. Esse segundo componente é invisível sem os coeficientes do próprio alvo, e um alvo grande o bastante para estimá-los poderia simplesmente ser corrigido dentro de si.

Para a prática, isso sugere três coisas. Quando a coorte-alvo é grande o bastante, ajuste a correção dentro dela. Quando os coeficientes precisam ser transportados, penalize-os com uma penalidade fixa e substancial, em vez de uma escolhida por validação cruzada na coorte de origem. E trate qualquer diagnóstico prévio, inclusive o índice de transporte, como ordenação de risco, não como garantia. A mesma cautela vale dentro de um único estudo: uma correção ajustada em controles e aplicada a pacientes é um transporte, e aqui ela mudou o efeito estimado da doença em até duas vezes.

5 Limitações

Cinco coortes adultas de sangue total, quatro em 450k e uma em EPIC, duas definidas por doença ou exposição; outros tecidos e idades não foram testados. Os painéis de referência foram construídos aqui com seleção de sondas mais simples que as bibliotecas publicadas. As medianas em tamanhos pequenos variam entre conjuntos independentes de sorteios (de +11,8% a +18,9% em 40 amostras), e o próprio dano em amostra pequena depende do relógio e da coorte de ajuste (neutro para o DunedinPACE a partir do GSE40279). O valor da penalidade é específico deste painel e destes relógios. A decomposição supõe um efeito linear da composição. A pontuação de sensibilidade com doze tipos usa o mesmo painel do ajuste. Nada disso diz respeito a se relógios epigenéticos medem envelhecimento biológico; trata de uma correção aplicada a eles.

6 Disponibilidade de dados e código

Todas as séries são públicas (GSE40279, GSE61151, GSE50660, GSE42861, GSE35069, GSE167998). O código de análise, o registro etapa a etapa com toda conclusão derrubada e os scripts das figuras estão em github.com/KTHimiko/clock-lab (a ser tornado público antes da submissão).

Referências

1. Jaffe, A. E. & Irizarry, R. A. Accounting for cellular heterogeneity is critical in epigenome-wide association studies. *Genome Biology* **15**, R31 (2014).
2. Zhang, Z., Salas, L. A., Christensen, B. C. & others. Deciphering the role of immune cell composition in epigenetic age acceleration: insights from cell-type deconvolution applied to human blood epigenetic clocks. *Aging Cell* **23**, e14071 (2024).
3. Tomusiak, A. & others. Development of an epigenetic clock resistant to changes in immune cell composition. *Communications Biology* **7**, 934 (2024).
4. McGregor, K. *et al.* An evaluation of methods correcting for cell-type heterogeneity in DNA methylation studies. *Genome Biology* **17**, 84 (2016).
5. Salas, L. A., Koestler, D. C., Christensen, B. C. & others. Enhanced cell deconvolution of peripheral blood using DNA methylation for high-resolution immune profiling. *Nature Communications* **13**, 761 (2022).
6. Horvath, S. DNA methylation age of human tissues and cell types. *Genome Biology* **14**, R115 (2013).
7. Levine, M. E. & others. An epigenetic biomarker of aging for lifespan and healthspan. *Aging* **10**, 573–591 (2018).

8. Horvath, S. & others. Epigenetic clock for skin and blood cells applied to Hutchinson Gilford Progeria Syndrome and ex vivo studies. *Aging* **10**, 1758–1775 (2018).
9. Belsky, D. W., Caspi, A., Corcoran, D. L. & others. DunedinPACE, a DNA methylation biomarker of the pace of aging. *eLife* **11**, e73420 (2022).
10. Eyre, B., Creager, E., Madras, D., Pappan, V. & Zemel, R. Out of the Ordinary: Spectrally Adapting Regression for Covariate Shift. em *Proceedings of the 41st International Conference on Machine Learning* vol. 235 12701–12722 (2024).
11. Lei, Q., Hu, W. & Lee, J. Near-Optimal Linear Regression under Distribution Shift. em *Proceedings of the 38th International Conference on Machine Learning* vol. 139 6164–6174 (2021).
12. Patil, P., Du, J.-H. & Tibshirani, R. J. Optimal Ridge Regularization for Out-of-Distribution Prediction. em *Proceedings of the 41st International Conference on Machine Learning* (2024).
13. Winkler, A. M., Webster, M. A., Vidaurre, D., Nichols, T. E. & Smith, S. M. Multi-level block permutation. *NeuroImage* **123**, 253–268 (2015).